Truy hồi thông tin y sinh đa ngôn ngữ (ViBioMIR)

Từ thu thập, chuẩn hóa dữ liệu đến xây dựng hệ thống truy hồi cơ sở

Nguyễn Hoàng Trung

Đại học Công nghệ, Đại học Quốc Gia Hà Nội (UET-VNU)

Ngày 12 tháng 10 năm 2026

Mục lục

Tổng quan bài toán

Dữ liệu ViBioMIR

Xây dựng baseline

Tổng quan bài toán

Một truy vấn, nhiều ngôn ngữ

- Đầu vào: một **truy vấn y khoa bằng tiếng Việt**.
- Kho dữ liệu: tài liệu từ các nguồn **Việt – Anh – Trung**.
- Hệ thống cần tìm đúng **tài liệu** và định vị đúng **đoạn nội dung gốc**.

Ví dụ

Cần làm gì đối với tình trạng tắc nghẽn đường tiết niệu do sỏi thận?

Đánh giá ở hai cấp độ

Document retrieval

D: tài liệu dự đoán. G: tài liệu tham chiếu.

$$P = \frac{|D \cap G|}{|D|}, \quad R = \frac{|D \cap G|}{|G|}.$$

Chunk retrieval

Precision: tỷ lệ chunk nộp được tính đúng.
Recall: tỷ lệ chunk tham chiếu tìm thấy.

Điểm F_2

$$F_2(q) = \frac{5P(q)R(q)}{4P(q) + R(q)}$$

$$F_2^{macro} = \frac{1}{|Q|} \sum_{q \in Q} F_2(q)$$

Tính từng truy vấn rồi lấy trung bình, riêng cho tài liệu và đoạn.

Ví dụ: đánh giá document

Kịch bản minh họa: $G = \{d_2, d_5, d_9\}$.

Trả 2 tài liệu	Trả 5 tài liệu
$D_A = \{d_2, d_5\}$	$D_B = \{d_2, d_5, d_9, d_{11}, d_{12}\}$
$P = 1,\ R = 2/3.$	$P = 0{,}6,\ R = 1.$
$F_2 \approx 0{,}714.$	$F_2 \approx 0{,}882.$

Bài học

Ví dụ B tìm đủ tài liệu liên quan nên có điểm cao hơn. Trả thêm tài liệu không liên quan vẫn làm precision giảm.

Một chunk đúng phải khớp thế nào?

- Đối chiếu trong **cùng truy vấn và cùng doc_id**.
- Chuẩn hóa NFKC, HTML entity, lowercase và khoảng trắng.
- LCS giữ thứ tự token nhưng không bắt buộc liên tiếp.

$$\text{overlap}(c, g) = \frac{\text{LCS}_{tokens}(c, g)}{|g|} \geq 0{,}40$$

Ví dụ

Đoạn tham chiếu 100 token, LCS 45 token: overlap = 45%, đạt ngưỡng.

Dữ liệu ViBioMIR

Tổng quan dữ liệu ViBioMIR

Kho tài liệu

- **4.394.718 URL** từ **97 host**.
- Mỗi tài liệu có một **ID** và một **URL**.
- Nội dung gồm nhiều nguồn và loại tài liệu khác nhau.

Tập truy vấn

- **1.200 câu hỏi tiếng Việt**.
- Độ dài trung vị: **18 từ**.
- Có câu hỏi ngắn và câu hỏi chứa nhiều ý.

Điểm cần phân biệt

Danh sách URL là điểm bắt đầu. Cần thu thập và xử lý nội dung trước khi có thể tìm kiếm.

Dữ liệu tập trung vào một số nguồn lớn

Nguồn	Số URL
www.cnkang.com	963.438
www.120ask.com	918.479
www.familydoctor.com.cn	447.453
ask.39.net	337.375
zysjonline.com	243.347

Ý nghĩa

Hai host lớn nhất chiếm khoảng 42,8% số URL. Cần hiểu cấu trúc nguồn lớn và vẫn quan sát các nguồn nhỏ để tránh bỏ sót loại tài liệu.

Các loại nội dung trong corpus

- **Hỏi đáp y khoa**: câu hỏi, câu trả lời và thông tin người trả lời.
- **Bài kiến thức**: bệnh, triệu chứng, chẩn đoán và điều trị.
- **Sách và cẩm nang**: chương, mục, bảng và tài liệu tham khảo.
- **Thuốc, dược liệu và tin tức**: cấu trúc và mục đích sử dụng khác nhau.

Vì sao cần phân biệt?

Mỗi loại tài liệu cần một cách trích xuất và chia đoạn phù hợp.

Nội dung lấy từ website có dùng được ngay không?

- Một trang web gồm bài viết, menu, quảng cáo và nội dung liên quan.
- Có trang chỉ trả về thông báo hoặc màn hình chọn ngôn ngữ.
- Tiêu đề, tác giả và ngày đăng có thể thiếu hoặc không đúng với bài.
- Cần nhận diện **phần nội dung chính** trước khi lập chỉ mục.

Câu hỏi cần kiểm tra

Văn bản đang thu được có phải là bài viết cần tìm và còn giữ đầy đủ cấu trúc quan trọng không?

Ví dụ 1: tải được trang nhưng chưa có bài viết

Nguyên nhân, triệu chứng và cách điều trị chóng mặt

`https://www.vinmec.com/vie/bai-viet/chong-mat-vi`

Bản thu thập ngày 11/10/2026

- Tiêu đề chỉ còn tên website.
- Trang thông báo chưa có nội dung tiếng Anh.
- Yêu cầu tiếp tục để đọc tiếng Việt.

Nếu đưa ngay vào chỉ mục

- Không có kiến thức về chóng mặt.
- Kết quả tìm kiếm có thể trả về thông báo thay cho bằng chứng.

Ví dụ 2: chọn đúng vùng bài và giữ cấu trúc

Bài viết trên Nhà thuốc Long Châu

1 bánh trung thu bằng mấy bát cơm? Góc nhìn dinh dưỡng và sức khỏe.

Những mục trong bài

- Thành phần dinh dưỡng trong 1 bánh Trung thu.
- Bánh nướng và bánh dẻo.
- Lượng calo trung bình.
- Các câu hỏi thường gặp.

Cách xử lý phù hợp

- Lấy vùng bài viết thay vì toàn bộ trang.
- Giữ tiêu đề mục cùng đoạn bên dưới.
- Chia đoạn theo từng mục để tìm đúng nội dung.

Các cách thu thập dữ liệu

- **Đọc HTML trực tiếp**: nhanh và đơn giản với trang tĩnh. Khó xử lý nội dung được tải bằng JavaScript.
- **API công khai**: dữ liệu thường có cấu trúc rõ. Không phải nguồn nào cũng cung cấp API.
- **Trình duyệt tự động**: lấy được trang cần render. Tốn thời gian và tài nguyên hơn.
- **Sitemap**: hỗ trợ tìm danh sách trang. Thường không cung cấp đầy đủ nội dung bài viết.

Cách lựa chọn

Khảo sát từng nguồn để chọn cách thu thập phù hợp trước khi mở rộng quy mô.

Từ URL đến dữ liệu có thể tìm kiếm

Danh sách URL

↓

Thu thập nội dung

↓

Trích xuất metadata và văn bản

↓

Làm sạch và chuẩn hóa

↓

Chia đoạn nội dung

↓

Lập chỉ mục và truy hồi

Chuẩn hóa metadata

- **Thông tin mô tả**: tiêu đề, tóm tắt, chuyên mục và ngôn ngữ.
- **Thông tin nguồn**: URL, tác giả, ngày đăng và ngày cập nhật.
- **Thông tin tổ chức**: loại tài liệu và nhóm chủ đề.
- Đưa các cách ghi khác nhau về một cấu trúc thống nhất.

Tại sao cần metadata?

Metadata giúp hiểu tài liệu, phân nhóm nội dung và hỗ trợ tìm kiếm trước khi đọc toàn văn.

Ví dụ: chuẩn hóa metadata

Cùng chủ đề, giữ nguyên tiêu đề và ngôn ngữ	
VI	Sỏi thận: triệu chứng và chẩn đoán
EN	Kidney stones: symptoms and diagnosis
ZH	肾结石：症状与诊断

Ngày đăng khác cách viết, cùng một định dạng
15/09/2026 | September 15, 2026 | 2026 年 9 月 15 日
⟶ 2026-09-15

Giữ riêng: ID, URL, tiêu đề gốc, ngôn ngữ và ngày đăng.
Thiếu thông tin thì để trống, không tự suy tác giả hay ngày đăng.

Chuẩn hóa nội dung văn bản

Bỏ phần giao diện, giữ phần bài viết

	Loại khỏi nội dung chính	Giữ tiêu đề bài
VI	Trang chủ / Tìm kiếm	Sỏi thận
EN	Home / Search	Kidney stones
ZH	首页 / 搜索 / 相关文章	肾结石

Làm sạch cách biểu diễn

`<p>Sỏi thận</p>` → Sỏi thận
`<p>Kidney stones</p>` → Kidney stones
 肾结石 → 肾结石

Giữ cấu trúc: tiêu đề mục, đoạn văn, danh sách và bảng.

Làm sạch nhưng không làm đổi nghĩa

Ba câu cùng mang ý phủ định

VI	**Không** ghi nhận sốt.
EN	**No** fever reported.
ZH	未报告发热

- Bỏ từ phủ định sẽ làm thay đổi thông tin của câu.
- Không xóa dấu tiếng Việt hoặc tự bỏ các từ được coi là ít quan trọng.
- Giữ nguyên số và đơn vị: **5 mg** khác **50 mg**.

Nguyên tắc

Làm sạch định dạng, không viết lại ý nghĩa. Lưu văn bản gốc để đối chiếu.

Tiền xử lý dữ liệu đa ngôn ngữ

Minh họa tách từ cho tìm kiếm từ khóa

	Văn bản	Một cách biểu diễn
VI	triệu chứng sỏi thận	triệu_chứng | sỏi_thận
EN	kidney stones symptoms	kidney | stones | symptoms
ZH	肾结石症状	肾结石 | 症状

- Tiếng Việt: khoảng trắng có thể nằm giữa các tiếng của một từ.
- Tiếng Trung: nhiều từ không được ngăn cách bằng khoảng trắng.
- Dense retrieval dùng tokenizer đi kèm mô hình.

Cùng khái niệm: sỏi thận ↔ kidney stones ↔ 肾结石.

Chunking: chia tài liệu thành các đoạn

Các cách chia phổ biến

- **Theo độ dài**: đơn giản và dễ kiểm soát.
- **Theo cấu trúc**: dựa trên câu, đoạn và tiêu đề mục.
- **Theo ngữ nghĩa**: gom các câu cùng chủ đề.

Đánh đổi cần cân nhắc

- Đoạn quá ngắn dễ mất ngữ cảnh.
- Đoạn quá dài dễ chứa nhiều nội dung không liên quan.
- Overlap giữ ngữ cảnh nhưng tạo nội dung trùng.

Tại sao cần chunking?

Truy hồi đoạn giúp định vị bằng chứng cụ thể thay vì trả về cả tài liệu dài.

Ví dụ: chia theo mục, giữ ngữ cảnh

Một bài, hai mục ở cả ba ngôn ngữ

	Tiêu đề bài	Mục 1	Mục 2
VI	Sỏi thận	Triệu chứng	Chẩn đoán
EN	Kidney stones	Symptoms	Diagnosis
ZH	肾结石	症状	诊断

- **Chunk A**: mục Triệu chứng và các câu thuộc mục này.
- **Chunk B**: mục Chẩn đoán và các câu thuộc mục này.

Câu hỏi về triệu chứng nên tìm đến chunk A.

Giữ ID và vị trí gốc để truy ngược mỗi chunk về tài liệu.

Ví dụ: giữ câu hỏi cùng câu trả lời

Tiếng Việt

Hỏi: Sỏi thận là gì?
Đáp: Sỏi thận là các khối rắn hình thành trong thận.

Tiếng Anh

Q: What are kidney stones?
A: Kidney stones are solid deposits that form in the kidneys.

Tiếng Trung

什么是肾结石？
肾结石是在肾脏内形成的固体沉积物。

Cách chia: giữ cặp hỏi đáp cùng đoạn nếu độ dài cho phép.

Hậu xử lý và kiểm tra chất lượng dữ liệu

Ví dụ: hai URL chứa cùng một bài tiếng Việt

A: Sỏi thận là các khối rắn hình thành trong thận.
B: Sỏi thận là các khối rắn hình thành trong thận.
→ Nhận diện bản trùng, vẫn giữ ánh xạ về các ID và URL gốc.

Cùng chủ đề chưa chắc là bản trùng

Sỏi thận | Kidney stones | 肾结石
→ Không xóa bài chỉ vì tiêu đề gần nghĩa hoặc khác ngôn ngữ.

- Kiểm tra trang lỗi, nội dung rỗng và đoạn mất ngữ cảnh.
- Giữ nguồn của từng chunk để trả về đúng bằng chứng.

Vì sao dữ liệu quyết định chất lượng truy hồi?

- Không thu thập được bài liên quan thì mô hình không thể tìm thấy bài đó.
- Trích xuất thiếu đoạn quan trọng thì bằng chứng bị mất.
- Nội dung nhiễu hoặc trùng làm kết quả tìm kiếm khó chính xác.
- Chia đoạn không phù hợp làm mất ngữ cảnh của câu trả lời.

Thông điệp

Mô hình tốt cần đi cùng một kho dữ liệu có độ phủ và chất lượng phù hợp.

Xây dựng baseline

Phân nhóm chủ đề dựa trên ICD-10

- ICD-10 tổ chức bệnh và vấn đề sức khỏe theo **hệ phân cấp**.
- Có thể bắt đầu bằng nhóm lớn như **tuần hoàn, hô hấp, nội tiết và tiêu hóa**.
- Dựa trên **tiêu đề, tóm tắt và chuyên mục** để gán nhóm chủ đề.
- Một tài liệu có thể thuộc nhiều nhóm.

Tại sao dùng ICD-10?

Có một hệ quy chiếu thống nhất để tổ chức dữ liệu và phân tích kết quả giữa các ngôn ngữ.

Các cách phân nhóm tài liệu

Dựa trên từ điển và quy tắc

- Khớp tên bệnh và từ đồng nghĩa.
- Dễ giải thích và không cần nhiều dữ liệu gán nhãn.
- Dễ bỏ sót cách diễn đạt mới hoặc từ nhập nhằng.

Dựa trên mô hình ngôn ngữ

- So khớp ngữ nghĩa hoặc phân loại văn bản.
- Nhận diện được nhiều cách diễn đạt.
- Cần kiểm tra nhãn sai và khả năng phù hợp y sinh.

Hướng tiếp cận

Bắt đầu bằng nhóm lớn, kết hợp nhiều tín hiệu và giữ trạng thái chưa xác định khi thiếu bằng chứng.

Ví dụ: nhóm chủ đề ICD-10 đa ngôn ngữ

Ba tiêu đề minh họa cùng một chủ đề	
VI	Đái tháo đường type 2
EN	Type 2 diabetes
ZH	2 型糖尿病

$\longrightarrow$ Nhóm **E00–E90**: bệnh nội tiết, dinh dưỡng và chuyển hóa.

- Từ điển đa ngôn ngữ giúp nối các tên gọi về cùng nhóm.
- Đọc thêm tóm tắt hoặc nội dung nếu tiêu đề chưa đủ rõ.
- Tài liệu có nhiều chủ đề có thể nhận nhiều nhóm.

Không suy chẩn đoán: tiêu đề "đau ngực" chưa đủ để kết luận bệnh mạch vành.

Dùng nhóm ICD-10 để làm gì?

- **Khám phá dữ liệu**: nhóm bệnh nào nhiều hoặc ít tài liệu?
- **Phân tích kết quả**: hệ thống làm tốt và chưa tốt ở nhóm nào?
- **Hỗ trợ tìm kiếm**: ưu tiên tài liệu thuộc nhóm chủ đề liên quan.
- **Hỗ trợ dữ liệu đa ngôn ngữ**: kết nối các cách gọi về cùng một nhóm.

Tránh lọc quá chặt

Câu hỏi có thể liên quan nhiều bệnh. Phân nhóm sai không nên làm mất toàn bộ tài liệu hữu ích.

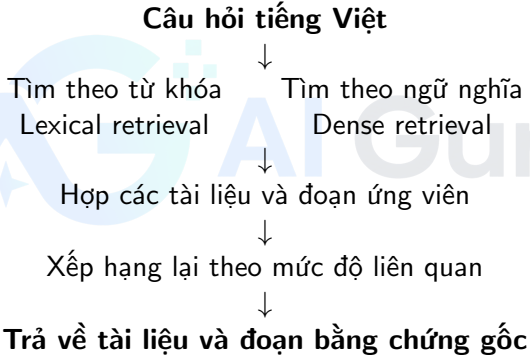
Các nhóm phương pháp trong baseline

Nhóm phương pháp	Ý tưởng	Ví dụ
Lexical retrieval	Khớp từ khóa	TF-IDF, BM25
Dense retrieval	So khớp vector ngữ nghĩa	mBERT, BGE-M3
Hybrid retrieval	Kết hợp lexical và dense	Hợp thứ hạng, RRF
Reranking	Đọc kỹ tập ứng viên	Cross-encoder

Mục đích của baseline

Bắt đầu bằng phương pháp đơn giản để hiểu dữ liệu, sau đó bổ sung thành phần khi giải quyết được một hạn chế cụ thể.

Kiến trúc tổng thể hệ thống truy hồi



Lexical retrieval: TF-IDF và BM25

TF-IDF

- Ưu tiên từ xuất hiện nhiều trong bài nhưng hiếm trong corpus.
- Dễ hiểu và dễ tạo mốc so sánh.
- Chưa mô hình hóa tốt ảnh hưởng của độ dài và lặp từ.

BM25

- Bổ sung bão hòa tần suất từ và điều chỉnh độ dài.
- Phù hợp với tài liệu có độ dài khác nhau.
- Vẫn phụ thuộc từ khóa xuất hiện trong văn bản.

Lexical retrieval: điểm mạnh và điểm yếu

Điểm mạnh

- Nhanh và tương đối ít tốn tài nguyên.
- Dễ giải thích vì sao tài liệu được chọn.
- Mạnh với thuật ngữ hoặc thực thể chính xác.

Điểm yếu

- Khó khớp từ đồng nghĩa và cách diễn đạt khác.
- Hạn chế khi query và tài liệu khác ngôn ngữ.
- Không hiểu đầy đủ ngữ cảnh của câu.

Tại sao vẫn dùng?

Là mốc so sánh đơn giản và bổ sung khả năng khớp chính xác mà tìm kiếm ngữ nghĩa có thể bỏ sót.

Dense retrieval: tìm kiếm theo ngữ nghĩa

- Mã hóa câu hỏi và đoạn văn thành **vector**.
- Các cách diễn đạt gần nghĩa được kỳ vọng nằm gần nhau trong không gian vector.
- Tìm các đoạn có vector gần với vector của câu hỏi.
- Ví dụ mô hình: **mBERT** và **BGE-M3**.

Ví dụ

Sỏi thận ↔ kidney stones ↔ 肾结石.
Ba cách viết có thể biểu đạt cùng một khái niệm.

Dense retrieval: điểm mạnh và điểm yếu

Điểm mạnh

- Khớp cách diễn đạt khác nhau.
- Có thể hỗ trợ truy hồi xuyên ngôn ngữ.

Điểm yếu

- Tốn tài nguyên mã hóa và lưu vector.
- Dễ nhầm đoạn gần nghĩa nhưng sai chi tiết.
- Phụ thuộc mô hình và miền dữ liệu.

Tại sao dùng?

Giảm khoảng cách ngôn ngữ giữa query và tài liệu. mBERT cần cách tạo vector và huấn luyện phù hợp. BGE-M3 được huấn luyện cho retrieval.

Hybrid retrieval: kết hợp hai cách tìm kiếm

Ý tưởng và điểm mạnh

- Lấy ứng viên từ lexical và dense.
- Kết hợp khớp từ chính xác với khớp ngữ nghĩa.
- Giảm phụ thuộc vào một cách biểu diễn.

Điểm yếu

- Phải vận hành nhiều chỉ mục.
- Cần chọn cách hợp kết quả phù hợp.
- Không bảo đảm tốt hơn nếu ứng viên có nhiều nhiễu.

Tại sao dùng?

Câu hỏi y khoa vừa cần đúng thuật ngữ, vừa có nhiều cách diễn đạt. Có thể hợp thứ hạng bằng RRF hoặc kết hợp điểm sau chuẩn hóa.

Reranking: xếp hạng lại tập ứng viên

Ý tưởng và điểm mạnh

- Đọc đồng thời câu hỏi và từng đoạn ứng viên.
- So khớp ngữ cảnh chi tiết hơn.
- Ưu tiên đoạn thực sự trả lời đúng câu hỏi.

Điểm yếu

- Chậm và tốn tính toán hơn retrieval.
- Chỉ xử lý một tập ứng viên nhỏ.
- Không tìm lại được bằng chứng đã bị bỏ sót.

Tại sao dùng?

Retrieval tìm rộng, reranking chọn kỹ. Ví dụ mô hình đa ngôn ngữ: BGE-reranker-v2-m3.

Ví dụ: cùng bệnh nhưng khác ý cần tìm

Câu hỏi tiếng Việt

Triệu chứng của sỏi thận là gì?

Ứng viên	Chủ đề của đoạn	Mức liên quan kỳ vọng
A (VI)	Chẩn đoán sỏi thận	Cùng bệnh, khác ý
B (EN)	Symptoms of kidney stones	Đúng ý triệu chứng
C (ZH)	肾结石: 症状	Đúng ý triệu chứng

- Lexical dễ khớp từ tiếng Việt ở A nhưng có thể bỏ sót B, C.
- Dense đa ngôn ngữ có thể đưa cả ba đoạn vào tập ứng viên.
- Reranker cần ưu tiên nội dung trả lời đúng ý, dù khác ngôn ngữ.

Từ kết quả tìm kiếm đến bằng chứng

- Gộp các đoạn thuộc cùng một tài liệu.
- Loại các đoạn bị lặp do chia đoạn chồng lấn.
- Chọn các đoạn liên quan đến từng ý trong câu hỏi.
- Trả về nội dung gốc và tài liệu nguồn tương ứng.

Mục tiêu

Tìm đúng tài liệu và đúng phần nội dung chứa thông tin cần tìm.

Đánh giá các phương pháp như thế nào?

- So sánh trên **cùng corpus, cùng bộ câu hỏi và cùng cách chia đoạn**.
- Đo **Precision, Recall và F_2** ở cấp tài liệu và đoạn.
- Xem thêm **thời gian tìm kiếm và tài nguyên sử dụng**.
- Phân tích theo ngôn ngữ, nhóm bệnh và loại câu hỏi.

Câu hỏi cần trả lời

Phương pháp mới cải thiện ở đâu, còn sai ở đâu và có đáng với chi phí bổ sung không?

Ba điểm cần nhớ

- **Dữ liệu**: thu thập đủ và giữ đúng nội dung trước khi tìm kiếm.
- **ICD-10**: giúp tổ chức chủ đề và hiểu hệ thống đang làm tốt ở nhóm nào.
- **Phương pháp**: lexical khớp từ, dense khớp nghĩa, hybrid kết hợp và reranker chọn kỹ.

Thông điệp

Chọn phương pháp theo đặc điểm dữ liệu và hạn chế cần giải quyết, sau đó kiểm chứng bằng thực nghiệm.

Cảm ơn và trao đổi

ICD-10: các chương I–XI

- **I–IV:** I · A00–B99: nhiễm trùng / ký sinh. II · C00–D48: khối u. III · D50–D89: máu / miễn dịch. IV · E00–E90: nội tiết / chuyển hóa
- **V–VIII:** V · F00–F99: tâm thần / hành vi. VI · G00–G99: thần kinh. VII · H00–H59: mắt. VIII · H60–H95: tai
- **IX–XI:** IX · I00–I99: tuần hoàn. X · J00–J99: hô hấp. XI · K00–K93: tiêu hóa

ICD-10: các chương XII–XXII

- **XII–XV:** XII · L00–L99: da. XIII · M00–M99: cơ xương / mô liên kết. XIV · N00–N99: tiết niệu / sinh dục. XV · O00–O99: thai sản
- **XVI–XIX:** XVI · P00–P96: chu sinh. XVII · Q00–Q99: dị tật bẩm sinh. XVIII · R00–R99: triệu chứng / dấu hiệu. XIX · S00–T98: chấn thương / ngộ độc
- **XX–XXII:** XX · V01–Y98: nguyên nhân bên ngoài. XXI · Z00–Z99: yếu tố sức khỏe / tiếp xúc dịch vụ. XXII · U00–U85: mã mục đích đặc biệt

Phụ lục: TF-IDF và BM25

TF-IDF

$$w_{t,d} = \mathrm{tf}(t,d)\,\mathrm{idf}(t)$$

- TF: mức xuất hiện trong tài liệu.
- IDF: mức phân biệt trong corpus.
- So sánh bằng cosine.

BM25

- Sử dụng độ hiếm của từ.
- Giảm lợi ích của việc lặp từ quá nhiều.
- Điều chỉnh theo độ dài tài liệu.

Khác biệt chính

BM25 bổ sung bão hòa tần suất từ và chuẩn hóa độ dài thay vì chỉ dựa trên trọng số TF-IDF.

Tài liệu tham khảo

- **ViBioMIR**: README và báo cáo kiểm kê dữ liệu.
- **Cuộc thi R2AI2026**: mô tả nhiệm vụ và phương pháp đánh giá.
- **WHO ICD-10**: hệ phân loại bệnh và vấn đề sức khỏe.
- **Introduction to Information Retrieval**: lexical retrieval.
- **Model cards**: mBERT, BGE-M3 và BGE-reranker.
- **Ví dụ thuật ngữ**: NIDDK, MSD Manuals và WHO.