ViBioMIR: Retrieval đa ngôn ngữ trên corpus hơn một triệu tài liệu

Tìm kiếm đa ngôn ngữ, corpus indexing và retrieval nâng cao

Nguyễn Tấn Minh

College of Engineering & Computer Science (CECS), VinUni

Ngày 22 tháng 10 năm 2026

Mục lục

Mở đầu

1. Kiến trúc tổng thể

2. Truy hồi thông tin đa ngôn ngữ

3. Indexing cho dữ liệu lớn

4. Các phương pháp truy hồi nâng cao

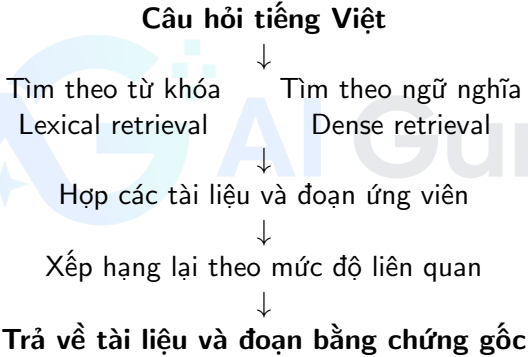
Tổng kết và thảo luận

ViBioMIR: truy hồi thông tin hai cấp độ

- Đầu vào: query tiếng Việt; nguồn bằng chứng: tiếng Việt, Anh và Trung.
- Quy mô: khoảng 1200 câu hỏi, nguồn thông tin từ 1.22M URLs.
- Đầu ra cấp document xác định nguồn liên quan; cấp passage xác định bằng chứng trong nguồn đó.

1. Kiến trúc tổng thể

Kiến trúc tổng thể hệ thống truy hồi



1. Pipeline ví dụ: từ document đến passage

- Query tiếng Việt $\rightarrow$ query gốc cùng bản dịch sát nghĩa sang tiếng Anh và Trung.
- Document stage A: lexical retrieval bằng BM25; kết hợp thứ hạng giữa các ngôn ngữ.
- Document stage B: multilingual dense reranking trên tập ứng viên lexical.
- Passage stage: chấm điểm passage trong tài liệu đã chọn, rồi rerank hoặc dùng LLM hợp lệ.

Document stage B: multilingual dense reranking

- Encode query tiếng Việt gốc bằng BGE-M3 hoặc multilingual encoder.
- Chấm điểm document vector đã tính sẵn trong shortlist; giữ khoảng 400 tài liệu.
- Bắt đầu với tiêu đề, đề mục và phần mở đầu.
- Encode theo phần đối với tài liệu dài, đa chủ đề.
- So sánh xếp hạng chỉ dùng dense với kết hợp lexical/dense trên cùng shortlist.

Nguồn: BGE-M3 model card.

Nguồn: Qwen3 Embedding and Reranking.

Dense embedding model: bảng so sánh

Model	Năm	Size	Ngôn ngữ	Domain
SapBERT (PubMedBERT)	2021	∼110M	EN	Biomedical concept/entity
BioLORD-2023	2023	∼110M	EN	Biomedical concept, semantic similarity
BGE-M3	2024	568M	Đa ngôn ngữ	General-purpose retrieval
multilingual-e5-large	2023	560M	Đa ngôn ngữ	General-purpose retrieval
Jina Embeddings v3	2024	570M	Đa ngôn ngữ	General-purpose, task-specific embedding
mGTE Base	2024	∼305M	Đa ngôn ngữ	General-purpose retrieval
MMed-Embed	2026	568M	Đa ngôn ngữ	Medical retrieval
Qwen3 Embedding	2025	0.6/4/8B	Đa ngôn ngữ	General-purpose, LLM-based embedding
NV-Embed-v2	2024	∼7.8B	EN	General-purpose, LLM-based embedding
SFR-Embedding-Mistral	2024	∼7B	Thiên về EN	General-purpose, LLM-based embedding

Tham khảo bảng xếp hạng embedding models cho dữ liệu y sinh tại: MTEB-Medical

Passage stage: tìm và chọn bằng chứng

- Lấy passage của 400 document ứng viên: nếu mỗi tài liệu có tám passage, tổng là khoảng 3,200.
- Chấm điểm passage vector và lexical match; giữ khoảng 400 passage để rerank.
- Dùng multilingual reranker với toàn bộ câu hỏi tiếng Việt; thử LLM trên tập nhỏ hơn.
- Cập nhật thứ hạng document từ passage score; chọn passage gốc cùng ID tài liệu cha.

Điểm chính

Số ứng viên: 2,000 document → 400 document → khoảng 3,200 passage → rerank 400 passage.

Nguồn: Qwen3 Embedding and Reranking.

Nguồn: Bài toán và đánh giá R2AI.

Reranker model: bảng so sánh

Model	Năm	Size	Ngôn ngữ	Domain / đặc điểm
MedCPT-Cross-Encoder	2023	∼110M	EN	Biomedical.
BGE-reranker-v2-m3	2024	∼0.6B	Đa ngôn ngữ	General-purpose; baseline nhỏ gọn
BGE-reranker-v2-gemma	2024	∼2B	Đa ngôn ngữ	General-purpose; LLM-based reranker
Jina Reranker v3.5	2026	0.6B	Đa ngôn ngữ	Listwise; tăng cường medical, legal, financial và structured data
mGTE Multilingual Reranker Base	2024	∼0.3B	Đa ngôn ngữ	General-purpose; phù hợp nhánh VI/EN/ZH
GTE Reranker ModernBERT Base	2025	149M	EN	General-purpose; bản mới hơn
Qwen3-Reranker	2025	0.6/4/8B	Đa ngôn ngữ	Text reranking; hỗ trợ instruction
Qwen3-VL-Reranker	2026	2/8B	Đa ngôn ngữ	Multimodal: text, image, video

2. Truy hồi thông tin đa ngôn ngữ

2. Giải pháp cho medical retrieval đa ngôn ngữ

- Dịch query và đối chiếu thuật ngữ giúp tăng hiệu quả khi truy hồi thông tin.
- Multilingual embedding so khớp câu hỏi tiếng Việt với tài liệu EN/ZH.

Điểm chính

Giữ đúng ngữ nghĩa, đặc biệt là thuật ngữ y khoa khi mở rộng phạm vi truy hồi.

Những lưu ý khi dịch query

- Lưu một bản dịch tiếng Anh và Trung sát nghĩa cho mỗi query tiếng Việt.
- Giữ nguyên thuật ngữ, tình trạng bệnh được mô tả trong query gốc.
- Rà soát thuật ngữ y khoa bằng mẫu song ngữ và nguồn chính thống.
- Dùng query tiếng Việt gốc làm cơ sở cho dense scoring và reranking.

Điểm chính

Bản dịch trôi chảy vẫn có thể bị sai lệch thông tin y khoa cần tìm kiếm.

Query translation: các hướng tiếp cận

1. **Direct translation:** Dùng mô hình dịch hoặc LLM để dịch trực tiếp query VI sang EN/ZH.
   Vilar et al., ACL 2023: Prompting PaLM for Translation.
2. **Glossary-augmented prompting:** Đưa thuật ngữ và bản dịch đã xác minh vào prompt để hướng dẫn hoặc hiệu chỉnh bản dịch.
   Bogoychev & Chen, WMT 2023: Terminology-Aware Translation.
3. **Retrieved few-shot examples:** Lấy các cặp câu song ngữ tương tự từ translation memory làm ví dụ trong prompt.
   Mu et al., Findings ACL 2023: Augmenting LLM Translators via Translation Memories.
4. **Domain-specific fine-tuning:** Fine-tune mô hình trên medical parallel data; MedEV cung cấp khoảng 360K cặp câu VI–EN.
   Vo et al., LREC-COLING 2024: Improving Vietnamese-English Medical Machine Translation.

Query translation: so sánh chi tiết

Kỹ thuật	Cách áp dụng	Ưu điểm / giới hạn	Ưu tiên
Direct translation	Dịch query VI sang EN/ZH; giữ query VI gốc.	Dễ triển khai; có thể sai thuật ngữ hoặc mất ngữ nghĩa.	Baseline
Glossary-augmented prompting	Đưa thuật ngữ y khoa liên quan và bản dịch đã xác minh vào prompt.	Kiểm soát thuật ngữ; cần chọn đúng nghĩa theo ngữ cảnh.	Cao
Retrieved few-shot examples	Lấy vài cặp query/câu y khoa song ngữ tương tự làm ví dụ.	Bổ sung ngữ cảnh; cần dữ liệu sạch, tránh sao chép chi tiết ngoài query.	Cao, sau baseline
Domain-specific fine-tuning	Fine-tune mô hình dịch trên medical parallel data, ví dụ MedEV cho VI–EN.	Học cách dùng từ trong miền; tốn training và cần dữ liệu đúng chiều dịch.	Khi có dữ liệu

3. Indexing cho dữ liệu lớn

Indexing 1M documents: các thách thức

- **Số lượng chỉ mục rất lớn.** Một document cần được tách thành nhiều đoạn hoặc vectors. Kĩ thuật multi-vector representation cần tốn thêm dung lượng lưu trữ.
- **Cấu trúc hai tầng: document–chunk.** Khó cấu trúc hóa dữ liệu. Ngoài ra, cần đánh giá số lượng chunk trước khi chọn phương pháp indexing.
- **Chi phí preprocessing và encoding.** Documents dài ngắn khác nhau, boilerplate, trùng lặp và lỗi extraction làm tăng thời gian xử lý và giảm chất lượng index.
- **Multilingual lexical indexing.** Nguồn dữ liệu đa ngôn ngữ (VI/EN/ZH) cần cách lưu trữ phù hợp.
- **Quản lý bộ nhớ và disk I/O.** Bộ nhớ cho embeddings, graph, IDs, metadata, và bộ nhớ tạm khi xây dựng hoặc tìm kiếm index.

Ước tính dung lượng cho embedding vectors

Representation	Kiểu lưu trữ	Dung lượng
1M document vector	1,024-d FP16	2.05 GB
8M passage vector	1,024-d FP16	16.38 GB
8M passage vector	1,024-d FP32	32.77 GB
8M passage code	64-byte PQ	0.512 GB

Nguồn: Tài liệu Faiss index.

Exact search và ANN: chính xác hay tốc độ?

Tiêu chí	Exact search (Flat)	Approximate Nearest Neighbor (ANN)
Đặc trưng	Chính xác 100% nhưng rất chậm.	Tìm kiếm gần đúng với độ trễ thấp.
Cách tìm	Tính khoảng cách với toàn bộ N vector, rồi chọn top-K.	Dùng đồ thị hoặc phân cụm để xét ít vector hơn. Có thể kết hợp nén vector.
Kết quả	Trả đúng top-K theo vector và độ đo đã chọn.	Trả xấp xỉ gần đúng top-K theo độ đo tương đồng.
Truy vấn	$O(Nd)$ cho tính khoảng cách, với d là số chiều. Chi phí tăng theo N.	Thường giảm độ phức tạp tính toán, tăng tốc độ truy hồi.
Chuẩn bị	Không cần xây đồ thị hay học phân cụm.	Tốn chi phí xây chỉ mục. Bộ nhớ phụ thuộc vào cấu trúc dữ liệu và mức độ nén vector.

Nguồn: Faiss.

Một số cấu trúc chỉ mục ANN

Hierarchical Navigable Small World (HNSW): đồ thị.
Inverted File (IVF): phân cụm. **Product Quantization (PQ):** nén biểu diễn vector.

Phương pháp	Lập chỉ mục và tìm kiếm	Điều chỉnh và đánh đổi
HNSW	Xây đồ thị nhiều tầng nối các vector lân cận. Tìm từ tầng thưa xuống tầng đáy.	Tăng `efSearch`: thường tăng recall và độ trễ. Tốn thêm RAM cho đồ thị.
IVF-Flat	Phân cụm vector thành `nlist` nhóm. Chỉ quét vector gốc trong `nprobe` nhóm gần query.	Tăng `nprobe`: giảm bỏ sót nhưng chậm hơn. Cần học bộ phân cụm.
IVF-PQ	Kết hợp IVF với PQ: nén từng phần vector bằng codebook.	Giảm bộ nhớ lưu vector, xuất hiện sai số khi nén vector. Cần học cả cụm và codebook.

Nguồn: Faiss: các loại chỉ mục; Faiss: tìm kiếm với IVF.

Các phương pháp indexing

Method	Vai trò trong pipeline	Trade-off / lưu ý
Inverted index BM25	Lấy candidate documents từ query VI và các bản dịch EN/ZH.	Hiệu quả với thuật ngữ chính xác; phụ thuộc analyzer và lexical overlap.
Exact scoring	Rerank document candidates; tìm passages trong các documents đã chọn.	Không có ANN approximation error; chi phí tăng theo số candidate vectors.
HNSW	Global dense retrieval khi có đủ RAM.	Graph tăng memory; điều chỉnh `efSearch` để cân bằng recall và latency.
IVF-Flat	Global dense retrieval bằng cách tìm trong một số clusters.	Cần train index; `nprobe` thấp có thể bỏ sót vectors liên quan.
IVF-PQ	Global dense retrieval khi memory hạn chế.	Nén vectors giúp giảm dung lượng; Sai số do quantization.

Nguồn: Faiss: index types và memory requirements.

Recommended packages: một stack tối giản

Thành phần	Package	Cách sử dụng đề xuất
Lexical document index	**Pyserini / Lucene**	BM25 trên title, headings và body. Kiểm tra analyzer cho VI/EN/ZH; fusion kết quả bằng RRF.
Candidate vector store	**NumPy memmap**	Lưu embeddings trên disk; đọc các vectors tương ứng candidate IDs. Sắp passage vectors liên tiếp theo document.
Exact dense scoring	**NumPy / PyTorch**	Batch dot product giữa query và candidate vectors; normalize nếu dùng cosine similarity.
Global dense index	**Faiss**	IndexFlat làm exact reference. Sử dụng HNSW, IVF-Flat hoặc IVF-PQ khi cần giảm chi phí truy hồi.
Search service	**OpenSearch**	Lựa chọn thay thế khi cần BM25, vector search, metadata filtering và API trong một hệ thống.

Nguồn: Pyserini; NumPy memmap; Faiss; OpenSearch.

4. Các phương pháp truy hồi nâng cao

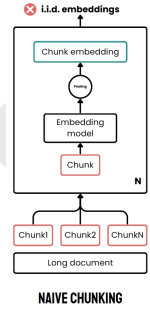
Late chunking: thêm ngữ cảnh khi chunking

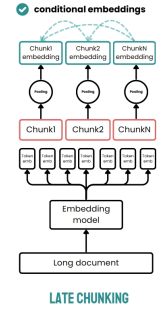
- Encode một cửa sổ tài liệu dài thành contextual token representation.
- Sau encoding, pooling token vector theo ranh giới từng chunk.

Điểm chính

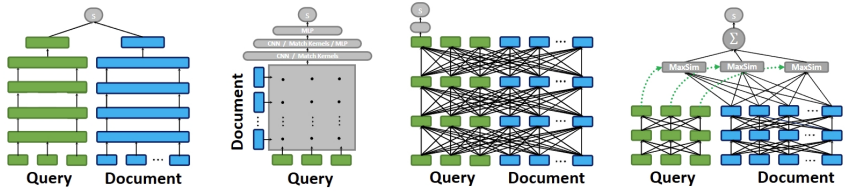
Vector biểu diễn mỗi chunk có thêm ngữ cảnh của toàn bộ văn bản.

Nguồn: Late Chunking.





Late interaction: matching chi tiết ở cấp token



- Giữ token vector của query và doc thay vì một pooled vector.
- Được tích hợp trong model BGE-M3 multi-vector scoring hoặc Jina-ColBERT-v2.

$$s(q,p) = \sum_i \max_j \langle \mathrm{q}_i, \mathrm{p}_j \rangle$$

Nguồn: BGE-M3 model card.

Tổng kết và Q&A

- Pipeline: lexical document retrieval → multilingual dense reranking → chọn passage bằng chứng.
- Truy hồi tài liệu y khoa đa ngôn ngữ: kết hợp dịch câu hỏi, multilingual embedding, LLM-based re-rankers.
- Lưu trữ và tìm kiếm đối với 1M văn bản: sử dụng ANN, Faiss.
- Nâng cao: late chunking, late interaction.

Cảm ơn và trao đổi

Tham khảo 1/2

1. Cuộc thi R2AI 2026. Tổng quan, đánh giá, dữ liệu và hướng dẫn nộp bài.
2. AI Guru. ViBioMIR dataset card. Thống kê corpus và data schema.
3. Chen et al. BGE M3-Embedding. 2024. arXiv:2402.03216.
4. Zhang et al. Qwen3 Embedding. 2025. arXiv:2506.05176.
5. Akram et al. Jina-embeddings-v5-text. 2026. arXiv:2602.15547.

Tham khảo 2/2

6. Günther et al. Late Chunking. 2024, cập nhật 2025. arXiv:2409.04701.
7. Jina-ColBERT-v2 model card. Late interaction đa ngôn ngữ.
8. Scheerer et al. WARP. SIGIR 2025. arXiv:2501.17788.
9. Jin et al. MedCPT. 2023. Mã nguồn NCBI chính thức và liên kết mô hình.
10. Faiss documentation. Chọn index, compression và tham số tìm kiếm.